Kapitel 1: Motivation

- Was sind disruptive Technologien?
- Wo wird datenintensiv gearbeitet?
- Warum benötigt man andere Systeme?
- Wie sehen Systeme für massive Daten aus?

„Disruptive Technology“

The Magazine



CURRENT ISSUE

November–December 2026

Why Employees Override AI: The problem isn't the technology. It's your organization.

Featuring

Why Even Your Best Employees Override AI Systems That Work

How CEOs Set the Tempo

How Leaders Counter Pessimism in Trying Times

Table of Contents

https://hbr.org/magazine

Disruptive Technologies: Catching the Wave
Joseph L. Bower and Clayton M. Christensen, 73(1):43–53, 1995.

Beispiele disruptiver Technologien

Internet

Auto

Smartphone

Musik

KI LLM

Videostreaming

Messbuch

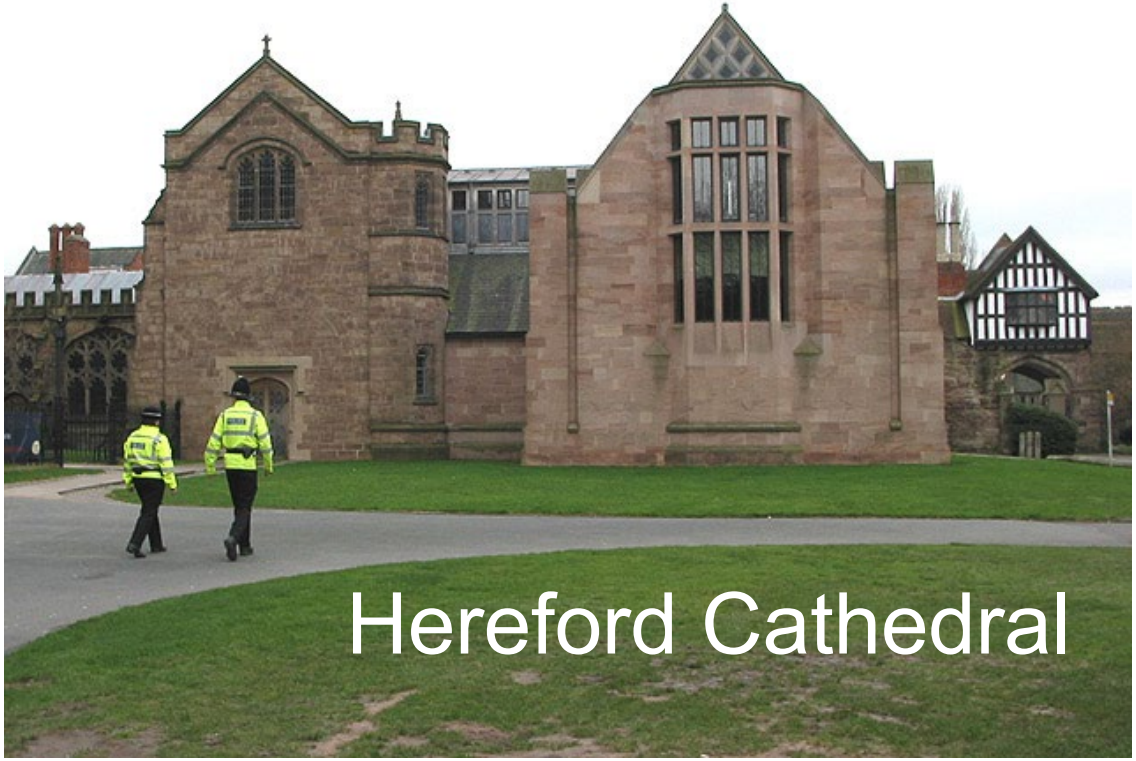


Unknown author (https://commons.wikimedia.org/wiki/File:Archive-ugent-be-AD88306A-B841-11E8-9E3D-BC34FC05B1B6_DS-343.jpg), https://creativecommons.org/licenses/by-sa/4.0/legalcode

Messbuch

- Litlyngton Missal
- Nicholas Litlyngton,
  Abt von Westminster Abbey,
  London, 1362–1386
- Produktionskosten:
  - Skriptor erhielt freie Unterkunft und Kleidung für 2 Jahre und
  - 4 Pfund (entsprach damals etwa Lohn für 200 Tage eines geübten Handwerkers)

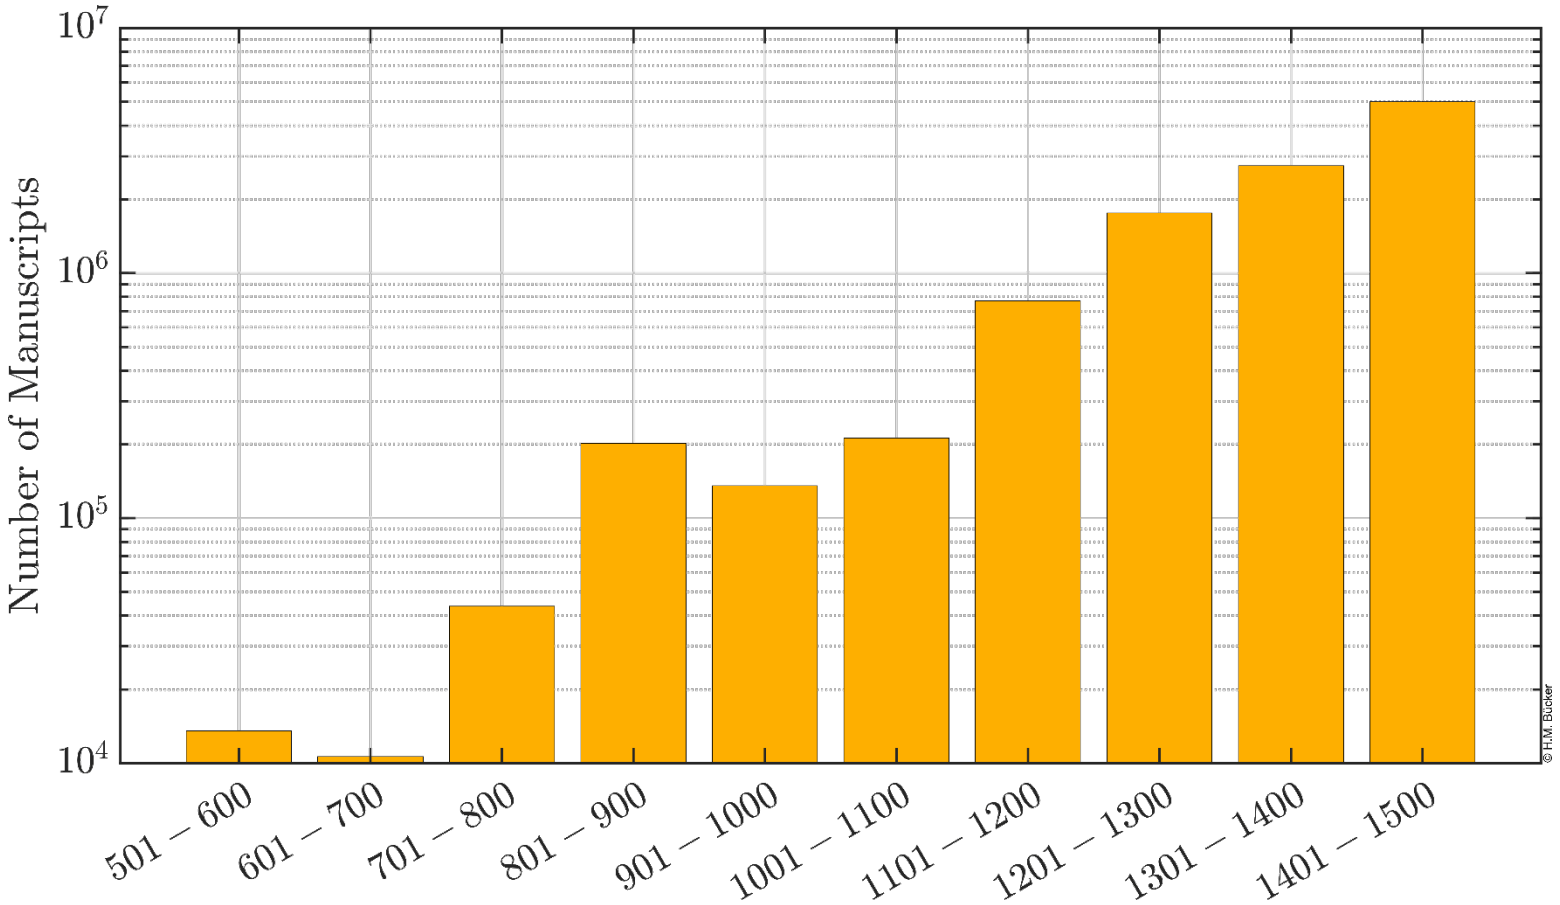
Chained Library



Pauline Eccles (https://commons.wikimedia.org/wiki/File:Mappa_Mundi_and_Chained_Library_are_housed_here_-_geograph.org.uk_-_665609.jpg), https://creativecommons.org/licenses/by-sa/2.0/deed.en

https://www.bbc.co.uk/culture/article/20180706-the-ancient-library-where-the-books-are-under-lock-and-key

Manuskripte bis 1500



Quelle: E. Buringh and J.L. Van Zanden. doi: 10.1017/S0022050709000837

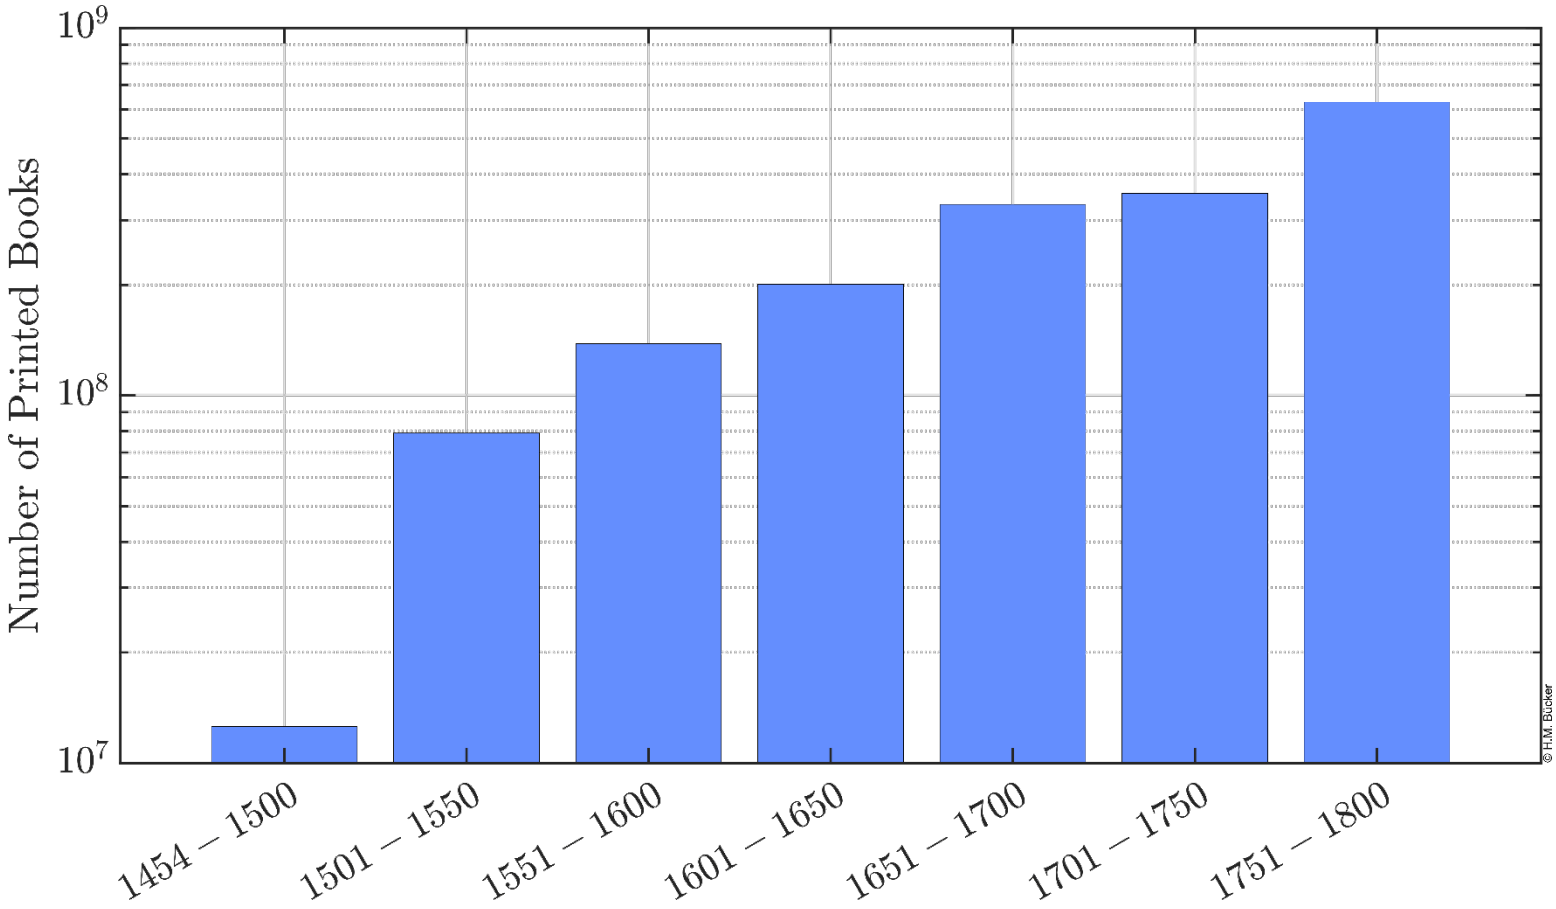
Johannes Gutenberg



Anonymous author via Wikimedia Commons

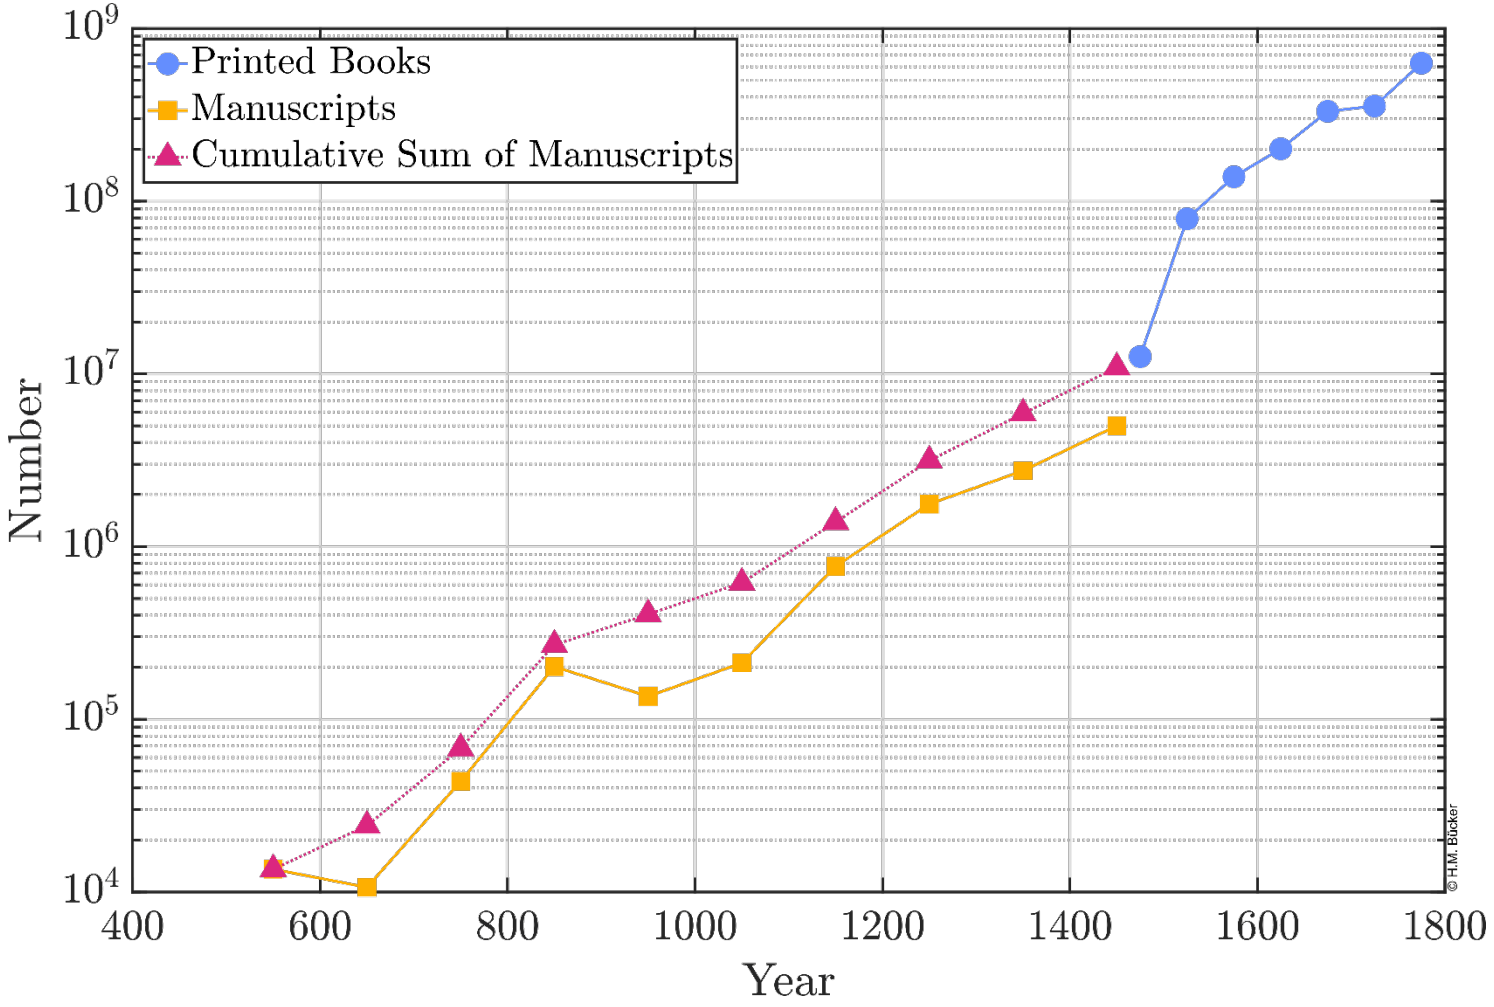
ca. 1400 – 1468

Gedruckte Bücher ab 1500



Quelle: E. Buringh and J.L. Van Zanden. doi: 10.1017/S0022050709000837

Erfindung des Buchdrucks um 1450



Quelle: E. Buringh and J.L. Van Zanden. doi: 10.1017/S0022050709000837

Anwendungsgebiete (Auswahl 1)

- Klima- und Wettervorhersage
- Gesundheitswesen
- Elektronischer Handel
- Medien und Unterhaltung
- Logistik
- Sicherheit
- Agrarwesen
- Bankwesen
- Reise und Touristik

Anwendungsgebiete (Auswahl 2)

- Autonomes Fahren
- World Wide Web
- Soziale Medien
- Marketing
- Cybersecurity
- …

Quotes from

The New York Times

The Cloud Factories

(Series of three articles in 2012.)

Quote 1:

Today, roughly a million gigabytes are processed and stored in a data center during the creation of a single 3-D animated movie, said Mr. Burton, now at EMC, a company focused on the management and storage of data.

Quote 2:

Just one of the company's clients, the New York Stock Exchange, produces up to 2,000 gigabytes of data per day that must be stored for years, he added.

Quote 3:

EMC and the International Data Corporation together estimated that more than 1.8 trillion gigabytes of digital information were created globally last year.

trillion = 10^{12} (American) oder 10^{18} (British)

Quote 4:

The survey did discover that the number of federal data centers grew from 432 in 1998 to 2,094 in 2010.

Amazon

Every day Amazon Web Services adds enough new capacity to support all of Amazon.com's global infrastructure through the company's first 5 years, when it was a $2.76 billion annual revenue enterprise

Quelle: R. Miller (Data Center Knowldege). A Look Inside Amazon's Data Centers, 2011.

Internationales Einheitensystem



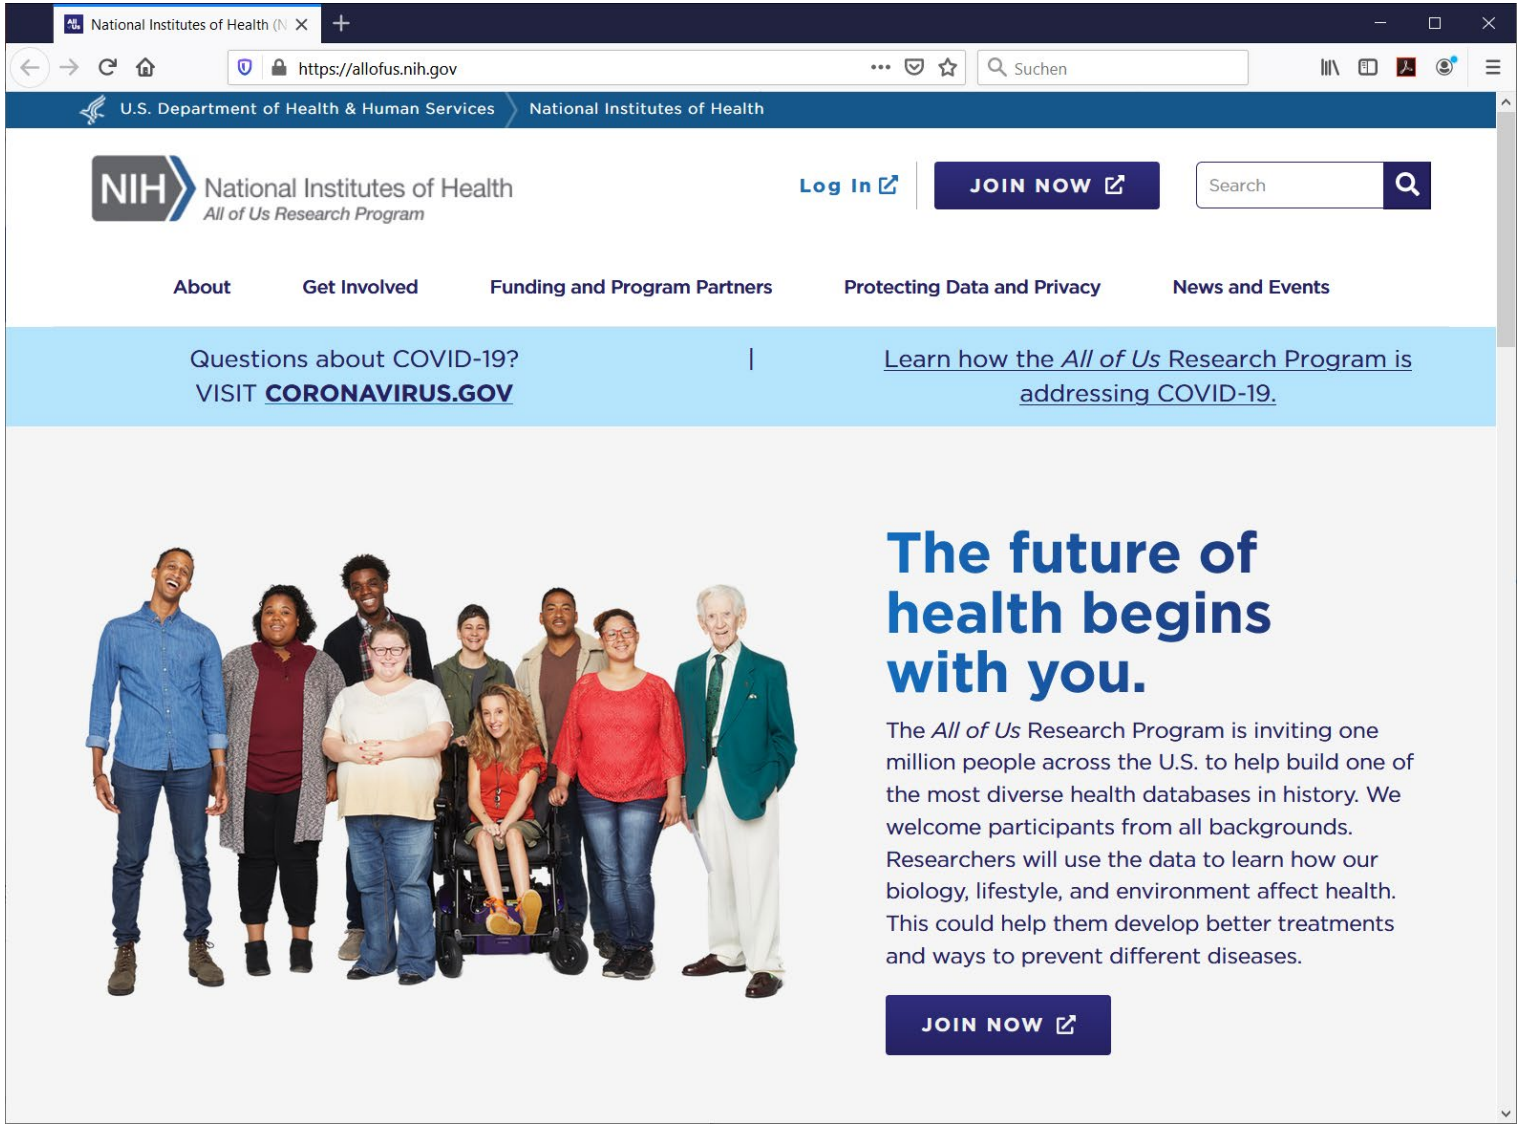
- Übergeordnetes Ziel: weltweite Vereinheitlichung von Messungen zu garantieren

Bureau International des Poids et Mesures. The International System of Units (SI). Ninth edition, 2019. Version V2.01, December 2022. https://creativecommons.org/licenses/by/3.0/igo/

SI-Präfixe

Präfix	Name	Wert	Zahlwort
K	Kilo	10^3	Tausend
M	Mega	10^6	Million
G	Giga	10^9	Milliarde
T	Tera	10^{12}	Billion
P	Peta	10^{15}	Billiarde
E	Exa	10^{18}	Trillion
Z	Zetta	10^{21}	Trilliarde
Y	Yotta	10^{24}	Quadrillion
R	Ronna	10^{27}	Quadrilliarde

All of Us Research Program



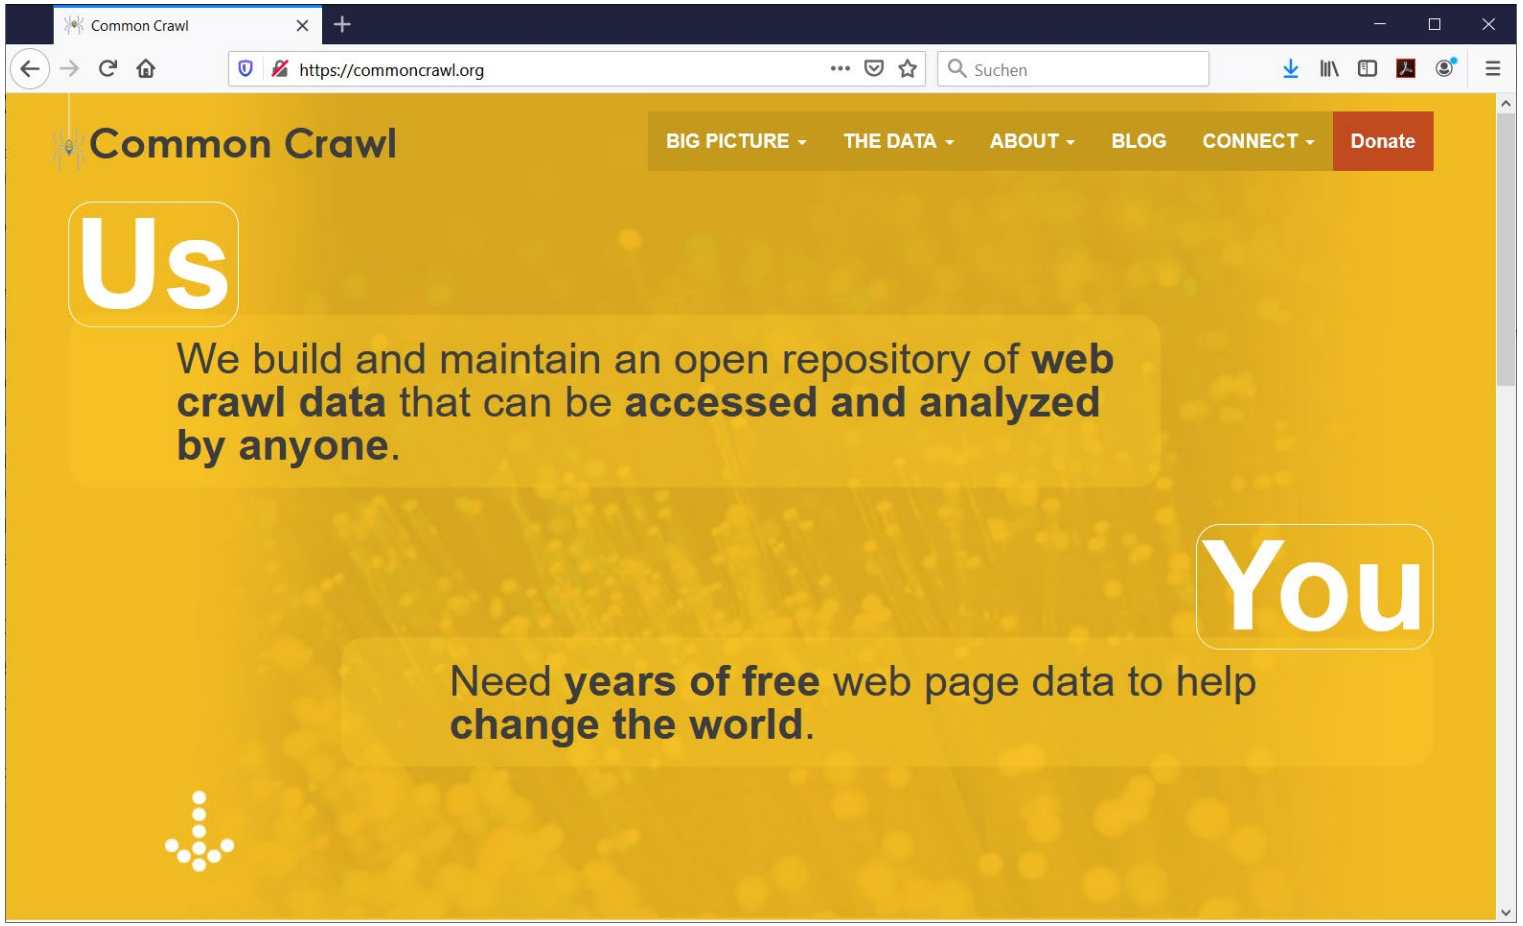
allofus.nih.gov

All of Us Research Program

- 350 000 Teilnehmende in Mai 2020
- 1 000 000 Teilnehmende in 2024 geplant
- 889 999 Teilnehmende in 2026
- Von mir angenommen: im Mittel Datensatz mit 100 MB/Person (Ist Annahme sinnvoll?)
- Größenordnung des Datenvolumens:

$$10^{14}\ \mathrm{B} = 100\ \mathrm{TB}$$

Common Crawl



commoncrawl.org

Common Crawl

- 3,45 Milliarden Webpages in Sept. 2020
- Größenordnung des Datenvolumens:

$$345 \cdot (1024)^4 \text{ B} = 379 \cdot 10^{12} \text{ B} \approx 380 \text{ TB}$$

- 2,8 Milliarden Webpages in Sept. 2024
- Größenordnung des Datenvolumens:

$$410 \cdot (1024)^4 \text{ B} = 451 \cdot 10^{12} \text{ B} \approx 450 \text{ TB}$$

Twitter bzw. X

- 500 M Tweets / min in 2015 je 3 KB
- Erwartete Größenordnung des Datenvolumens im Jahre 2025:

$$1,4 \cdot 10^{15}\ \mathrm{B} = 1,4\ \mathrm{PB}$$

YouTube

- Upload von 300 h video / min in 2015
- Erwartet (1000 bis 1700) h video / min in 2025
- Erwartete Größenordnung des Datenvolumens im Jahre 2025:

$$1 \text{ bis } 2 \cdot 10^{18} \text{ B} \approx 1 \text{ EB}$$

Astronomie

Australien Square Kilometer Array Path Finder



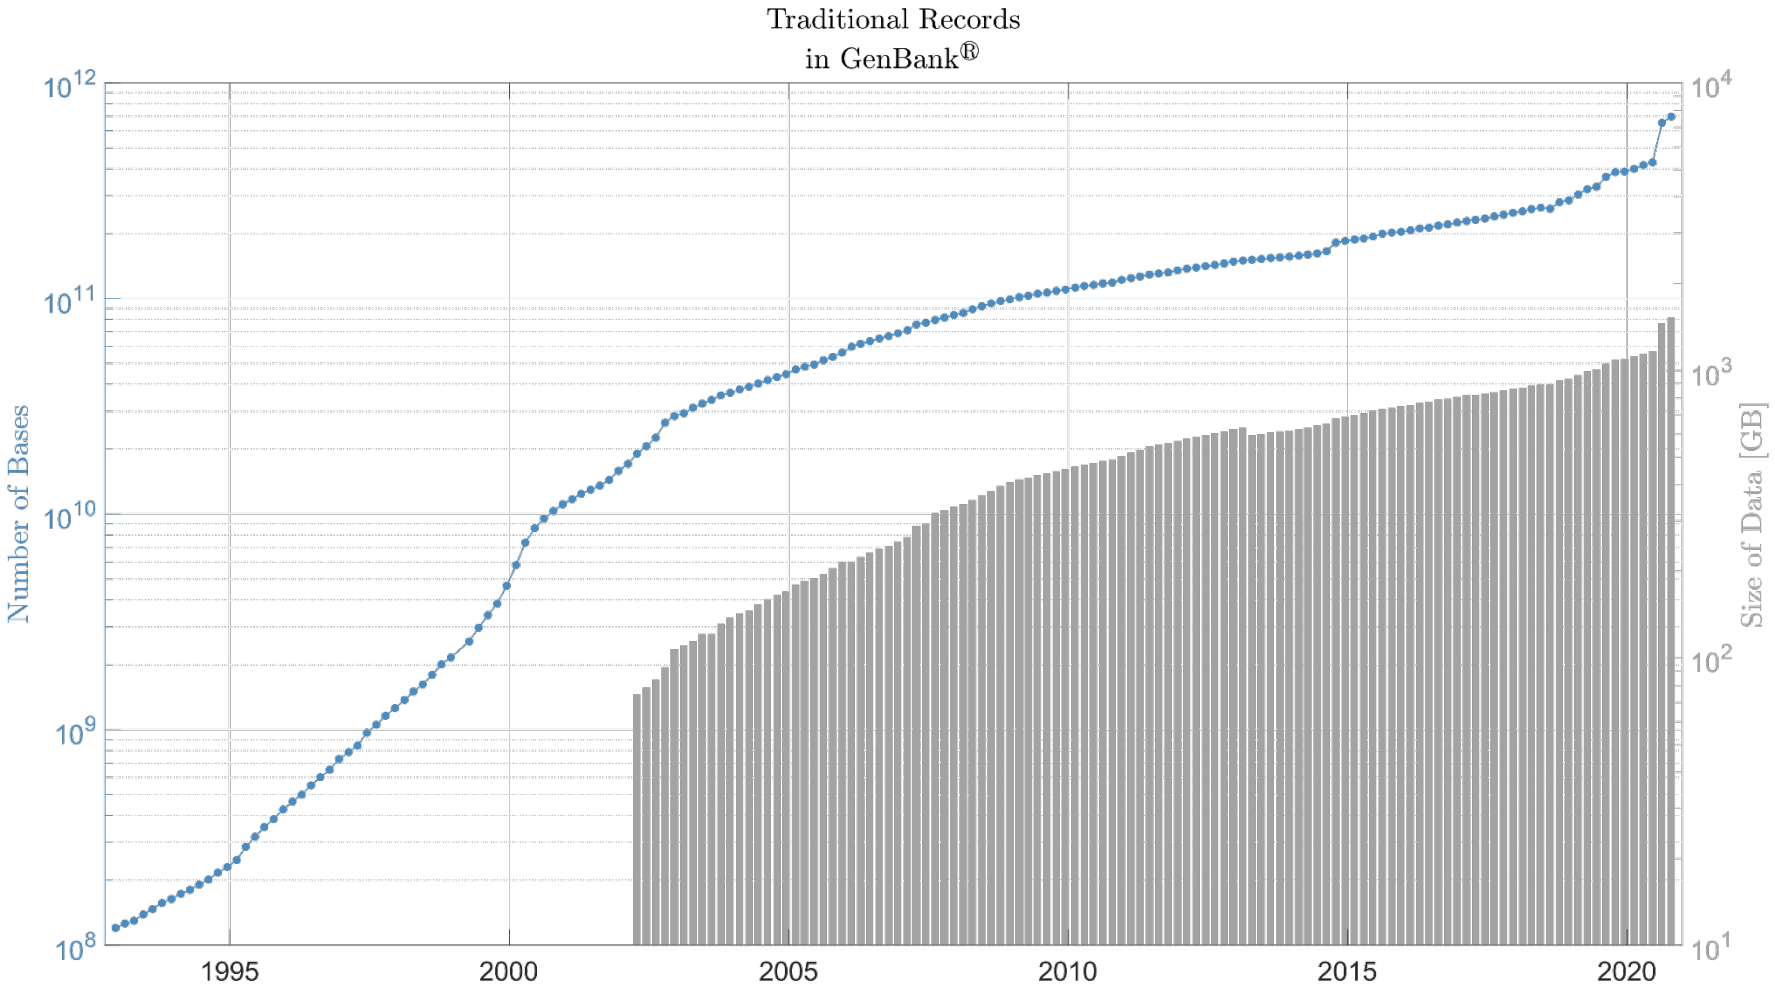
CSIRO (https://commons.wikimedia.org/wiki/File:CSIRO_ScienceImage_2161_Close_up_of_a_radio_astronomy_telescope_with_several_more_in_the_background.jpg), https://creativecommons.org/licenses/by/3.0/legalcode

Astronomie

- Australien Square Kilometer Array Path (ASKAP) Finder
- 7,5 PB/sec in 2015
- Erwartet 750 PB/sec in 2025
- Erwartete Größenordnung des Datenvolumens im Jahre 2025:

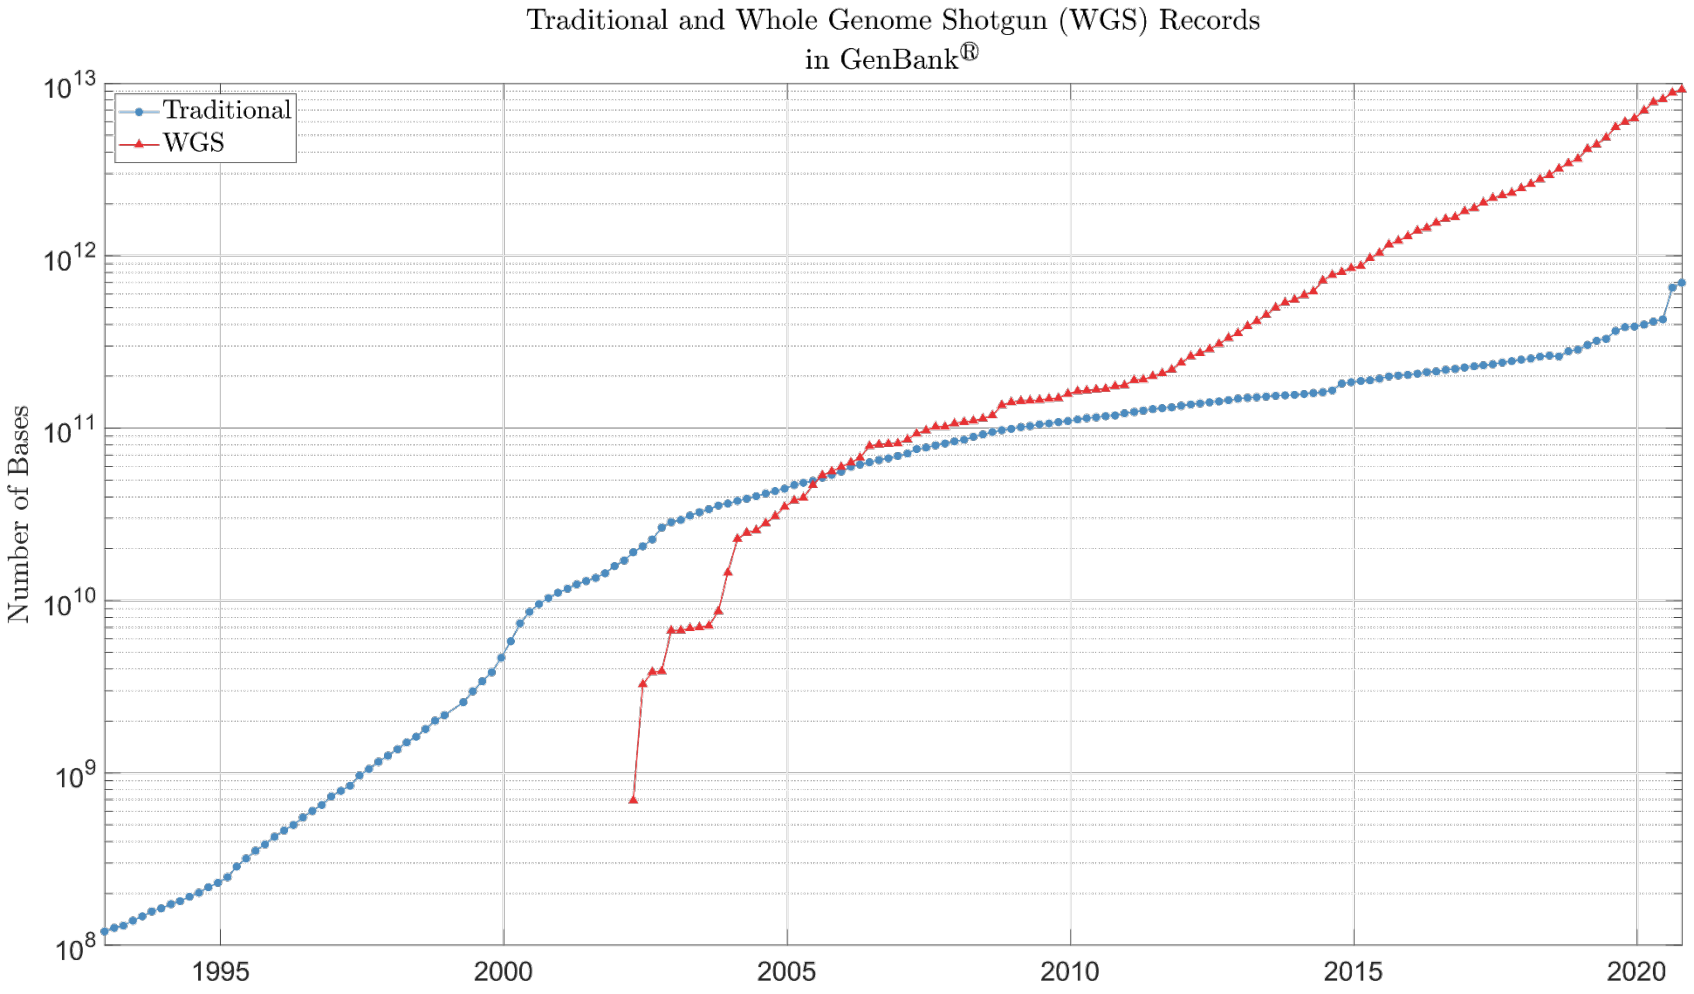
$$25 \cdot 10^{21}\ \mathrm{B} = 25\ \mathrm{ZB}$$

Anzahl von Basen und Größe



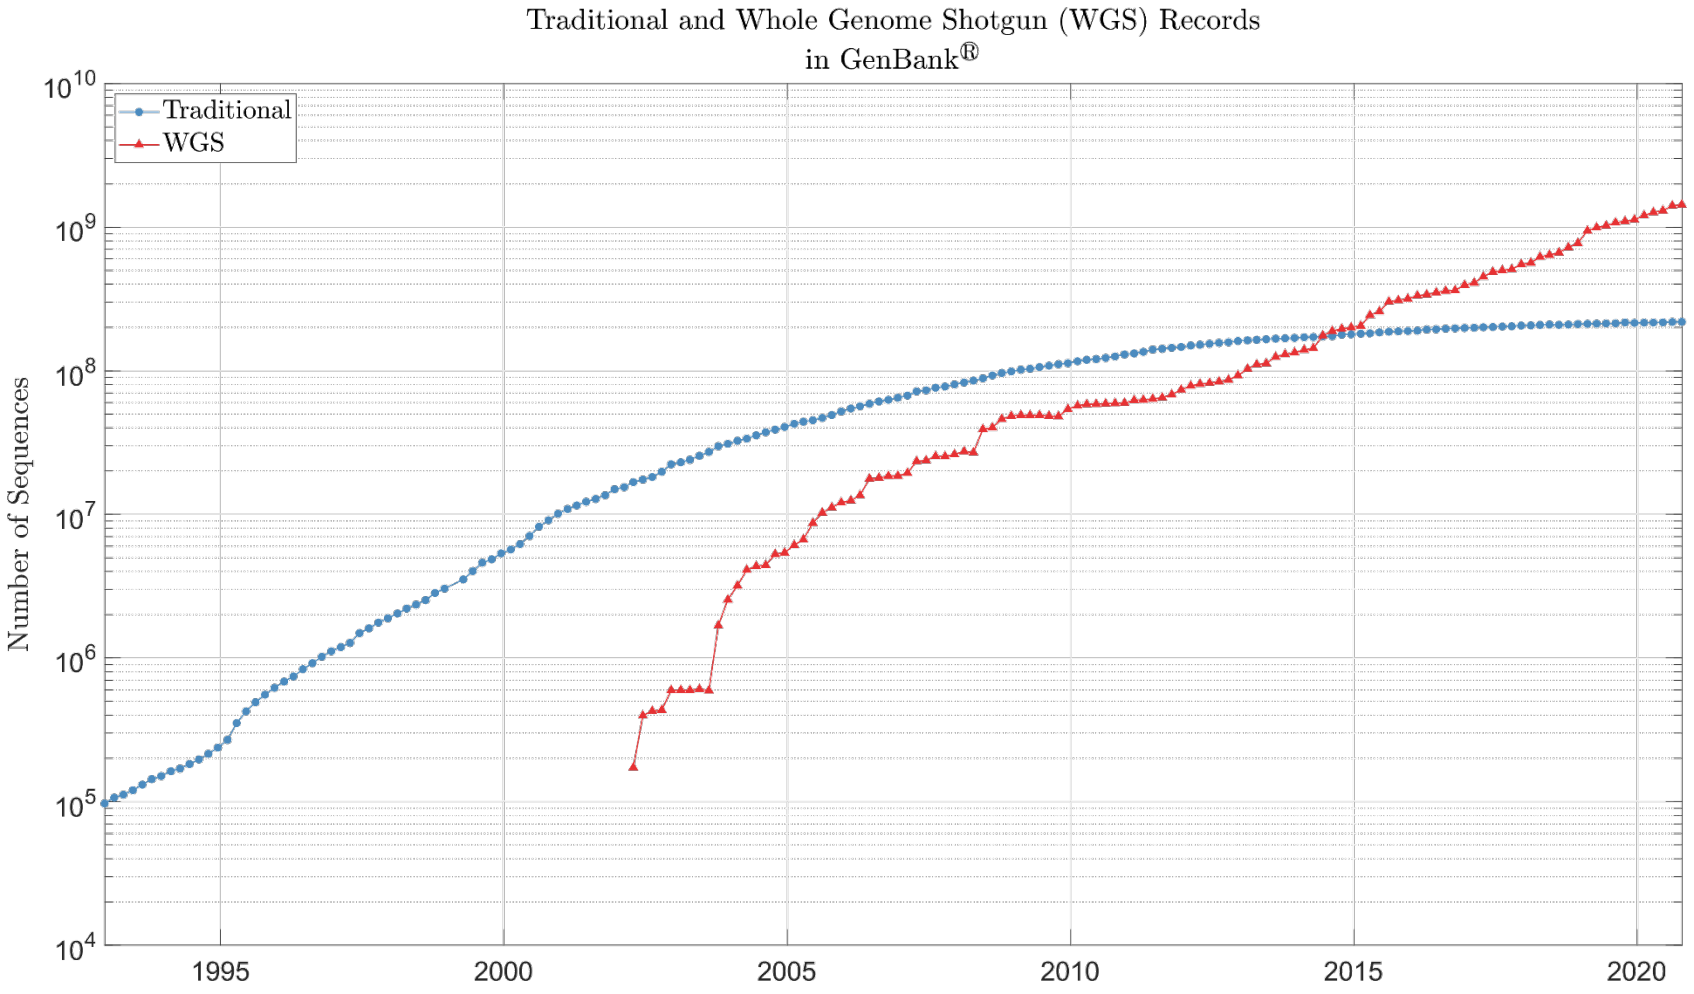
© H.M. Bücker

Anzahl von Basen



© H.M. Bücker

Anzahl von Sequenzen



© H.M. Bücker

Typische Datenvolumina

Bezeichnung	Volumina	Einlesedauer	
All of us	100 TB		
Common Crawl	400 TB		
Twitter	1 PB		
YouTube	1 EB		
ASKAP	25 ZB		
Sequenzierung	? ZB		

Realitätscheck (SSD 660p)

- Intel Solid-State Drive 660p Series
  - Launched: August 2018
  - 512 GB, 1 TB, 2 TB
  - 70 €, 110 €, 220 €
  - PCIe 3.0
  - Bandbreite Sequential Read < 1.8 GB/s

Realitätscheck (SSD 665p)

- Intel Solid-State Drive 665p Series
  - Launched: November 2019
  - 1 TB, 2 TB
  - ca 100 €, ?€
  - PCIe 3.0
  - Bandbreite Sequential Read < 2.0 GB/s

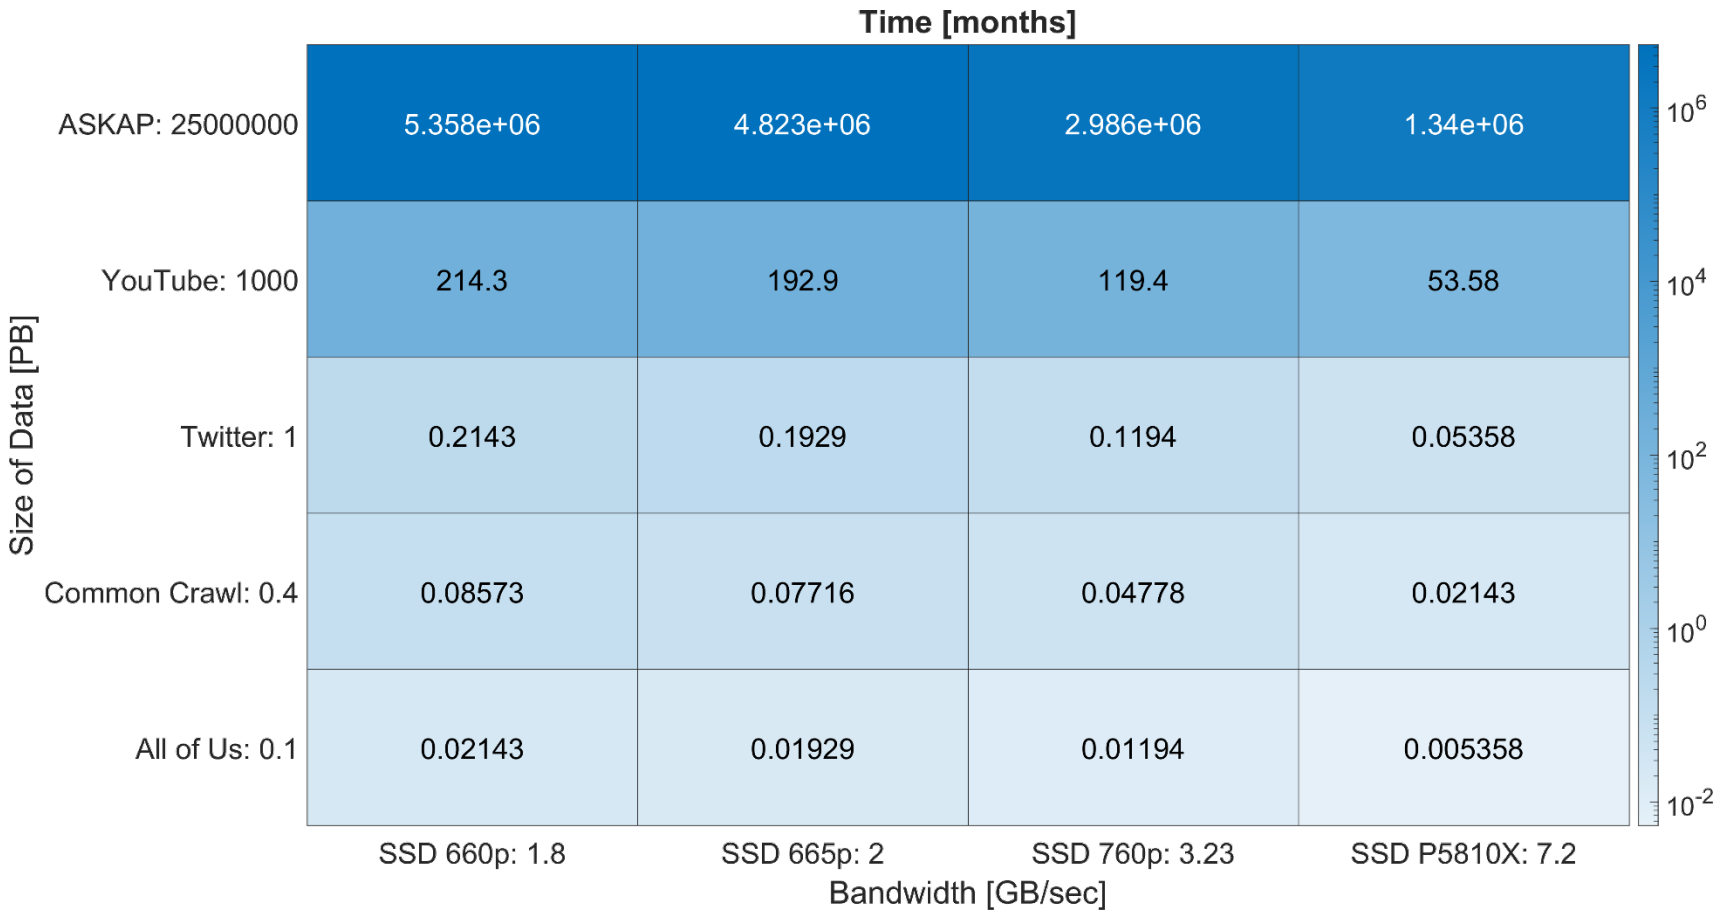
Realitätscheck (SSD 760p)

- Intel Solid-State Drive 760p Series
  - Launched: January 2018
  - 128 GB, 256 GB, 512 GB, 1 TB, 2 TB
  - 50 €, 60€, 100 €, 200 €, 360 €
  - PCIe* Gen3
  - Bandbreite Sequential Read < 3.23 GB/s
  - 1.6 M hours Mean Time Between Failure

Realitätscheck (SSD DC P5810X)

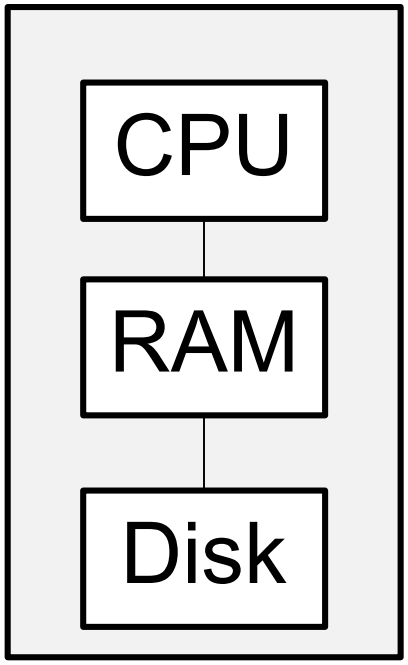
- Intel Optane SSD DC P5810X Series
  - Launched: October 2022
  - 800 GB
  - > 1200 € (in 10/2024)
  - PCIe* Gen4.0 x4
  - Bandbreite Sequential Read < 7.2 GB/s
  - 2.0 M hours Mean Time Between Failure

Untere Grenze für Einlesezeiten



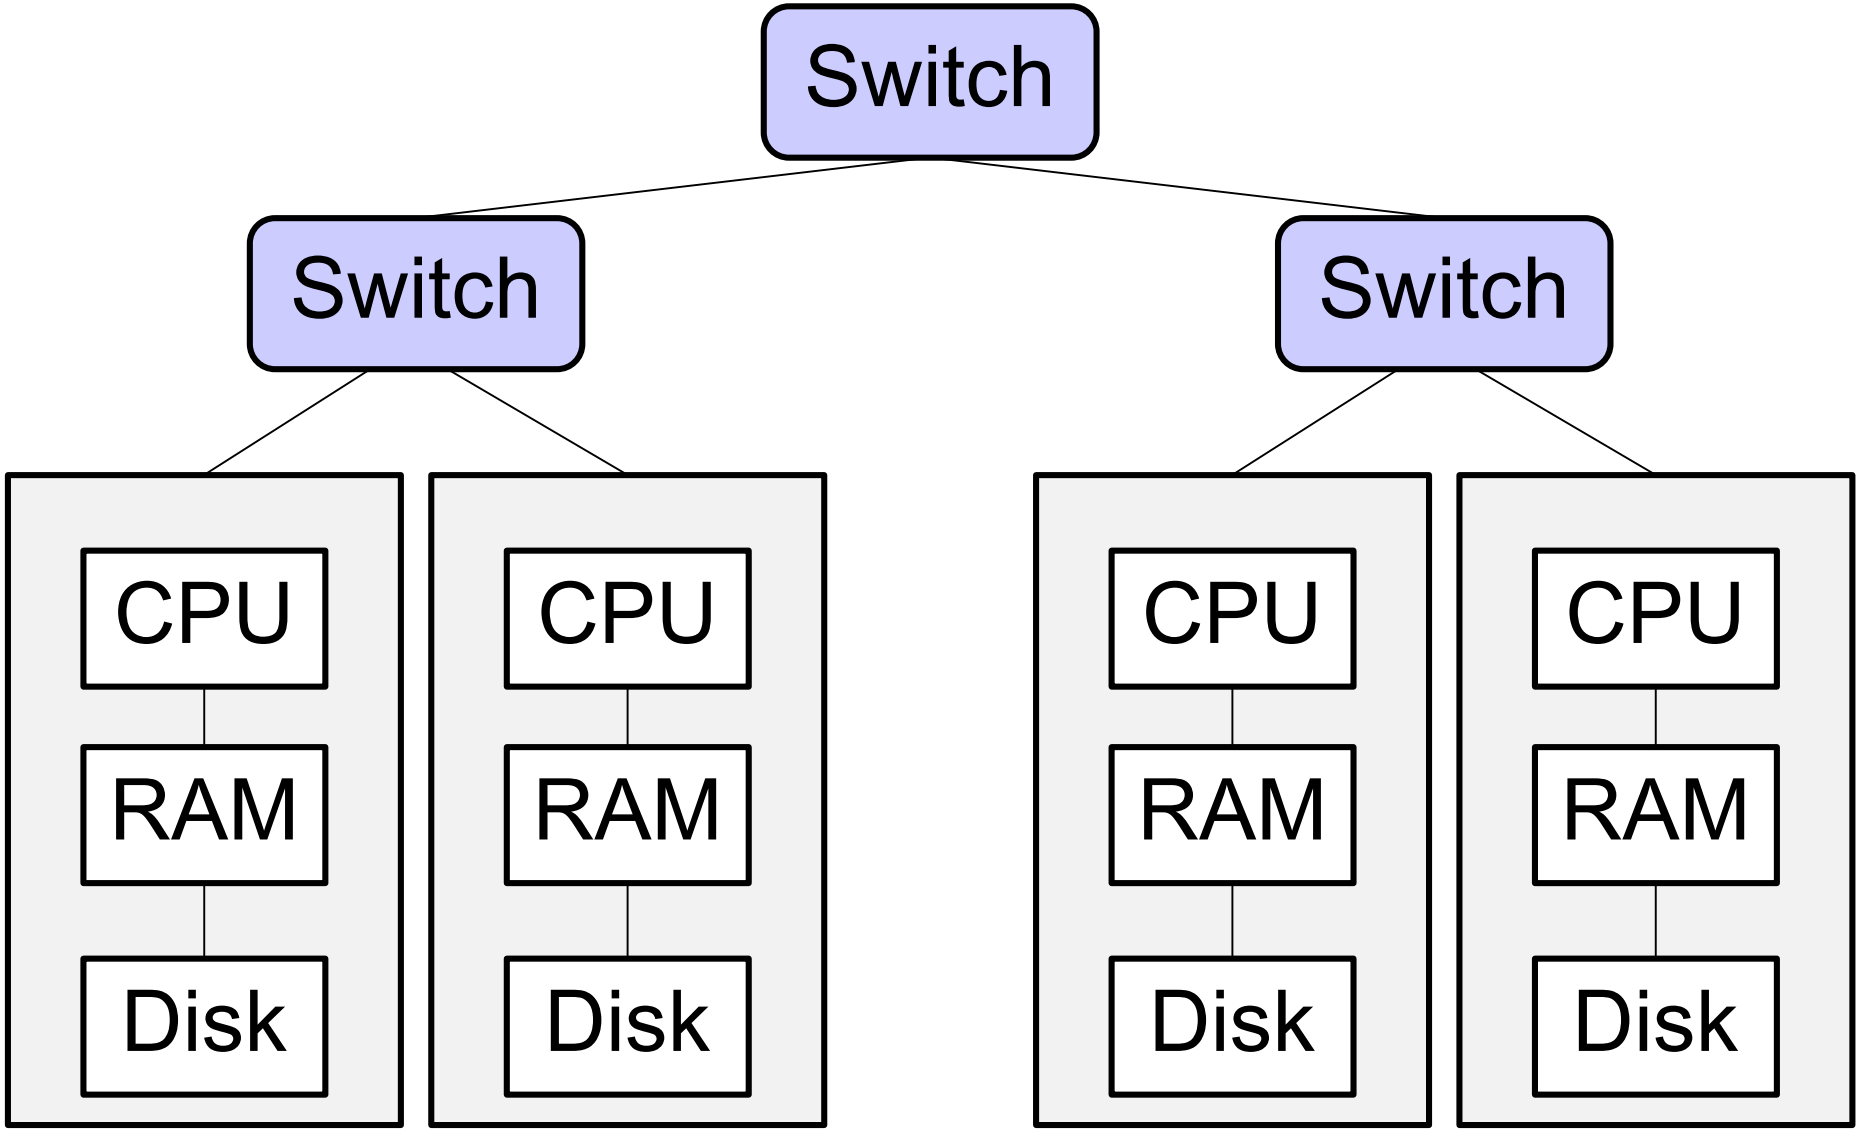
© H.M. Bücker

„Traditional“ Compute Node



© H.M. Bücker

Cluster of Compute Nodes



© H.M. Bücker

Motivation (Teil 1)

- Motivation
  - „Big Data“ meint „> TByte“ oder „web-scale“
  - Reguläre Daten
  - Parallelverarbeitung
- Cluster von Compute Nodes meint hier
  - Commodity hardware
  - Hohe Knotenanzahl
  - „Langsame“ Verbindung über Ethernet via switches

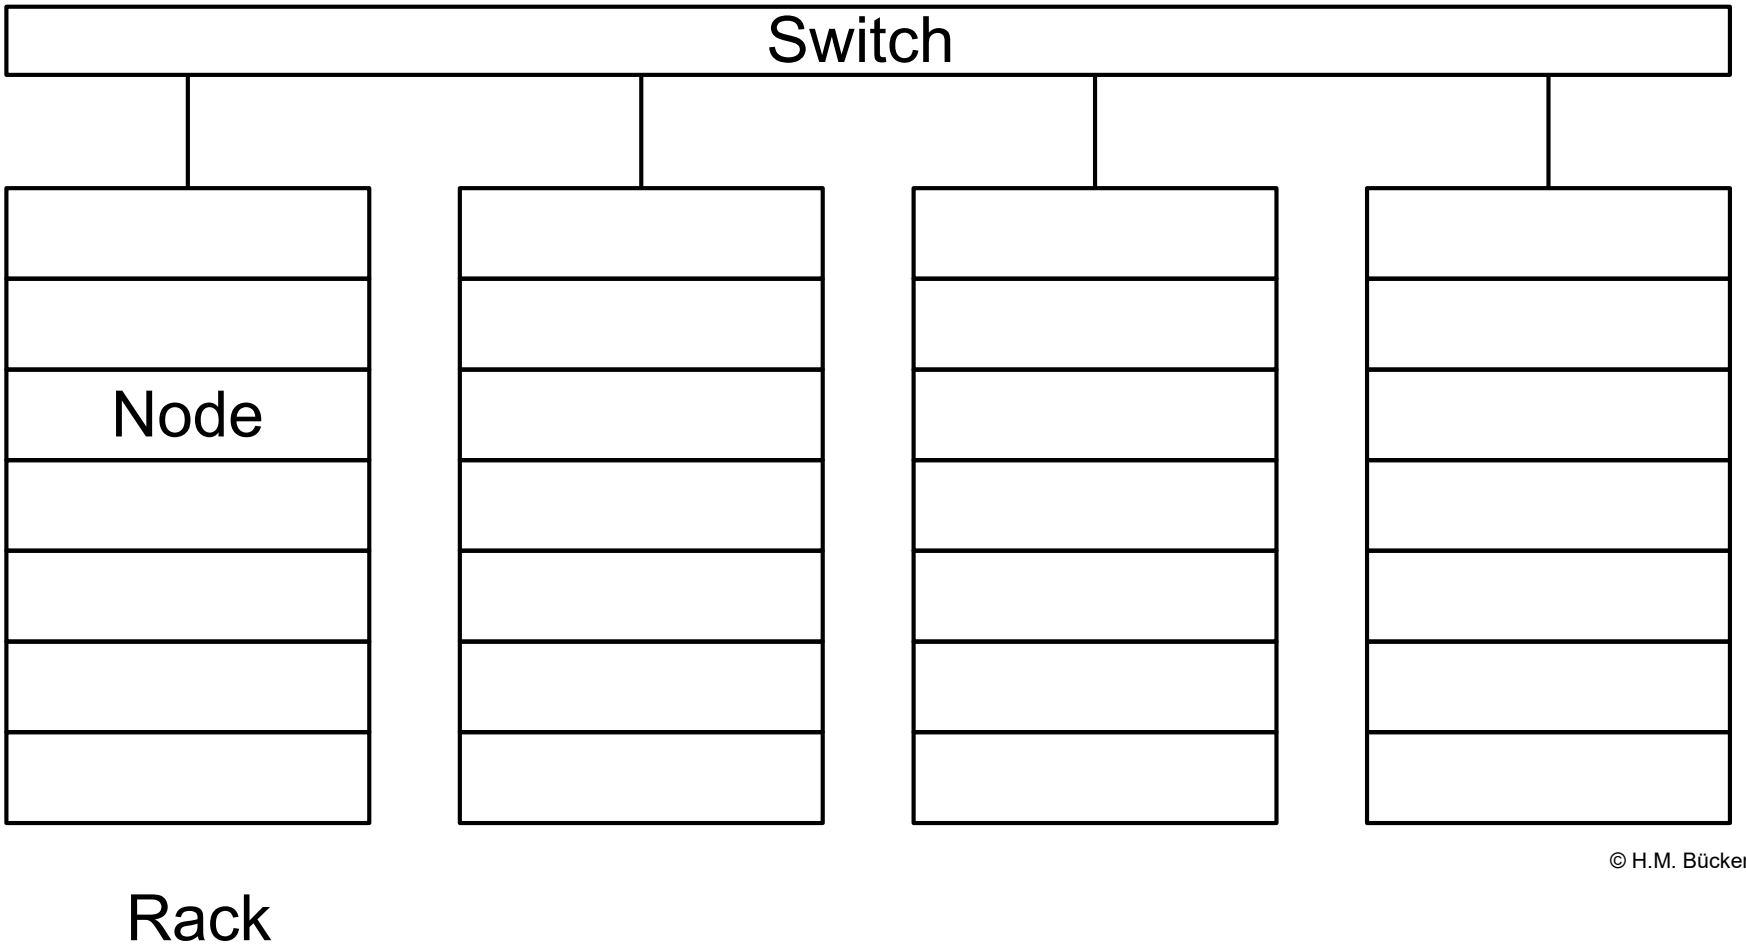
Motivation (Teil 2)

- Herausforderungen
  - „Echte“ Datenverteilung
  - Auftreten von Fehlern ist „normal“
- MapReduce
  - Spezielles Programmiermodell für diese Klasse von Anwendungen
  - Einfache Benutzung (High Productivity)

Motivation (Teil 3)

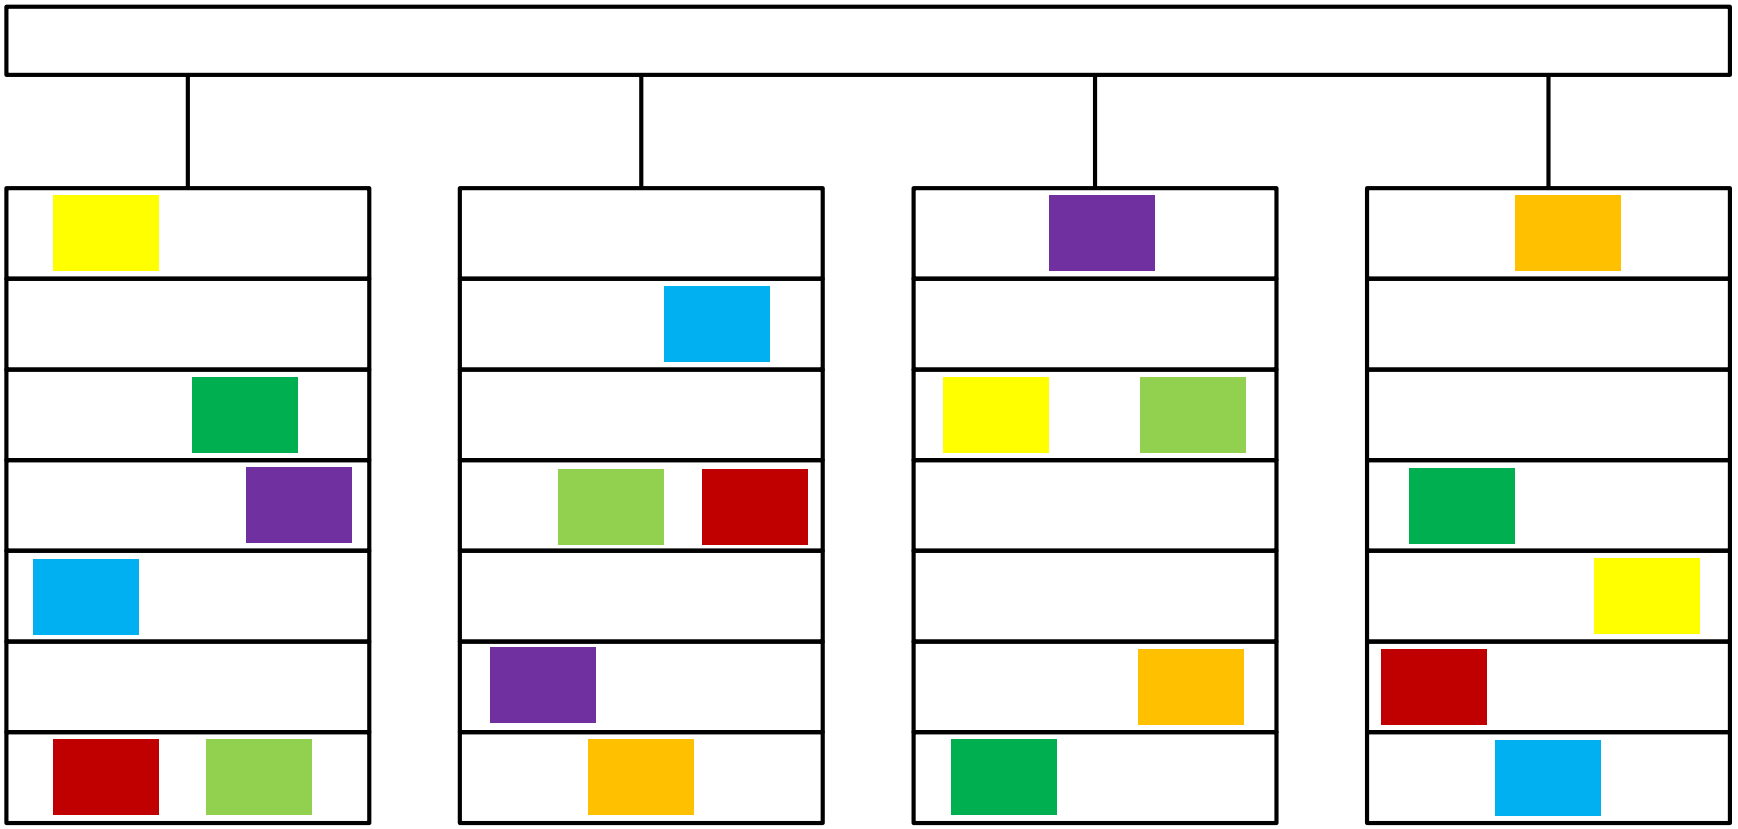
- Folgerungen aus Fehlertoleranz
  - Dateien müssen redundant gespeichert werden (Distributed Files System)
  - Berechnungen werden in Teilaufgaben zerlegt, die im Fehlerfall neu gestartet werden können.

Cluster of Racks of Compute Nodes



© H.M. Bücker

Distributed File System



© H.M. Bücker

Datei 

Amazon EC2

- https://aws.amazon.com/de/ec2/pricing/on-demand/
- AWS-Region: Frankfurt
- Stand: 25.10.2021

Instance-Name	On-Demand-Stundensatz ▼	vCPU	Arbeitsspeicher	Speicherung	Netzwerkleistung
u-12tb1.112xlarge	131,733 USD	448	12288 GiB	Nur EBS	100 Gigabit
u-9tb1.112xlarge	98,80 USD	448	9216 GiB	Nur EBS	100 Gigabit
u-6tb1.112xlarge	65,867 USD	448	6144 GiB	Nur EBS	100 Gigabit
u-6tb1.56xlarge	55,9796 USD	224	6144 GiB	Nur EBS	100 Gigabit
p4d.24xlarge	40,94475 USD	96	1152 GiB	8 x 1000 SSD	400 Gigabit
x1e.32xlarge	37,344 USD	128	3904 GiB	2 x 1920 SSD	25 Gigabit
p3.16xlarge	30,584 USD	64	488 GiB	Nur EBS	25 Gigabit

Amazon EC2

- https://aws.amazon.com/de/ec2/pricing/on-demand/
- AWS-Region: Frankfurt
- Stand: 13.10.2024

Instance-Name	On-Demand-Stundensatz	vCPU	Arbeitsspeicher	Speicherung	Netzwerkleistung
u-18tb1.112xlarge	197,60 USD	448	18432 GiB	Nur EBS	100 Gigabit
u-12tb1.112xlarge	131,733 USD	448	12288 GiB	Nur EBS	100 Gigabit
u-9tb1.112xlarge	98,80 USD	448	9216 GiB	Nur EBS	100 Gigabit
u-6tb1.112xlarge	65,867 USD	448	6144 GiB	Nur EBS	100 Gigabit
u-6tb1.56xlarge	55,9796 USD	224	6144 GiB	Nur EBS	100 Gigabit
p4d.24xlarge	40,94475 USD	96	1152 GiB	8 x 1000 SSD	400 Gigabit
x2iedn.32xlarge	37,348 USD	128	4096 GiB	2 x 1 900 NVMe-SSD	100 Gigabit
x2iedn.metal	37,348 USD	128	4096 GiB	2 x 1 900 NVMe-SSD	100 Gigabit

Amazon EC2

- https://aws.amazon.com/de/ec2/pricing/on-demand/
- AWS-Region: Frankfurt
- Stand: 06.10.2025

Instance-Name	On-Demand-Stundensatz	vCPU	Arbeitsspeicher	Speicherung	Netzwerkleistung
u7in-16tb.224xlarge	217,71657 USD	896	16384 GiB	Nur EBS	200 Gigabit
u7i-12tb.224xlarge	151,49759 USD	896	12288 GiB	Nur EBS	100 Gigabit
u7i-8tb.112xlarge	100,99555 USD	448	8192 GiB	Nur EBS	100 Gigabit
u7i-6tb.112xlarge	75,74705 USD	448	6144 GiB	Nur EBS	100 Gigabit
u-6tb1.112xlarge	65,867 USD	448	6144 GiB	Nur EBS	100 Gigabit
u-6tb1.56xlarge	55,9796 USD	224	6144 GiB	Nur EBS	100 Gigabit
g6e.48xlarge	37,67612 USD	192	1536 GiB	4 x 1 900 GB NVMe-SSD	400 Gigabit
x2iedn.32xlarge	37,348 USD	128	4096 GiB	2 x 1 900 NVMe-SSD	100 Gigabit

Amazon EC2

- https://aws.amazon.com/de/ec2/pricing/on-demand/
- AWS-Region: Frankfurt
- Stand: 17.10.2026

Instance-Name	On-Demand-Stundensatz	vCPU	Arbeitsspeicher	Speicherung	Netzwerkleistung
u7in-24tb.224xlarge	326,6006 USD	896	24576 GiB	Nur EBS	200 Gigabit
u7in-16tb.224xlarge	217,71657 USD	896	16384 GiB	Nur EBS	200 Gigabit
u7i-12tb.224xlarge	151,49759 USD	896	12288 GiB	Nur EBS	100 Gigabit
u7i-8tb.112xlarge	100,99555 USD	448	8192 GiB	Nur EBS	100 Gigabit
u7i-6tb.112xlarge	75,74705 USD	448	6144 GiB	Nur EBS	100 Gigabit
u-6tb1.112xlarge	65,867 USD	448	6144 GiB	Nur EBS	100 Gigabit
x8i.metal-96xl	58,82304 USD	384	6144 GiB	Nur EBS	100000 Megabit
x8i.96xlarge	58,82304 USD	384	6144 GiB	Nur EBS	100000 Megabit

Top Ten List (as of 2010)

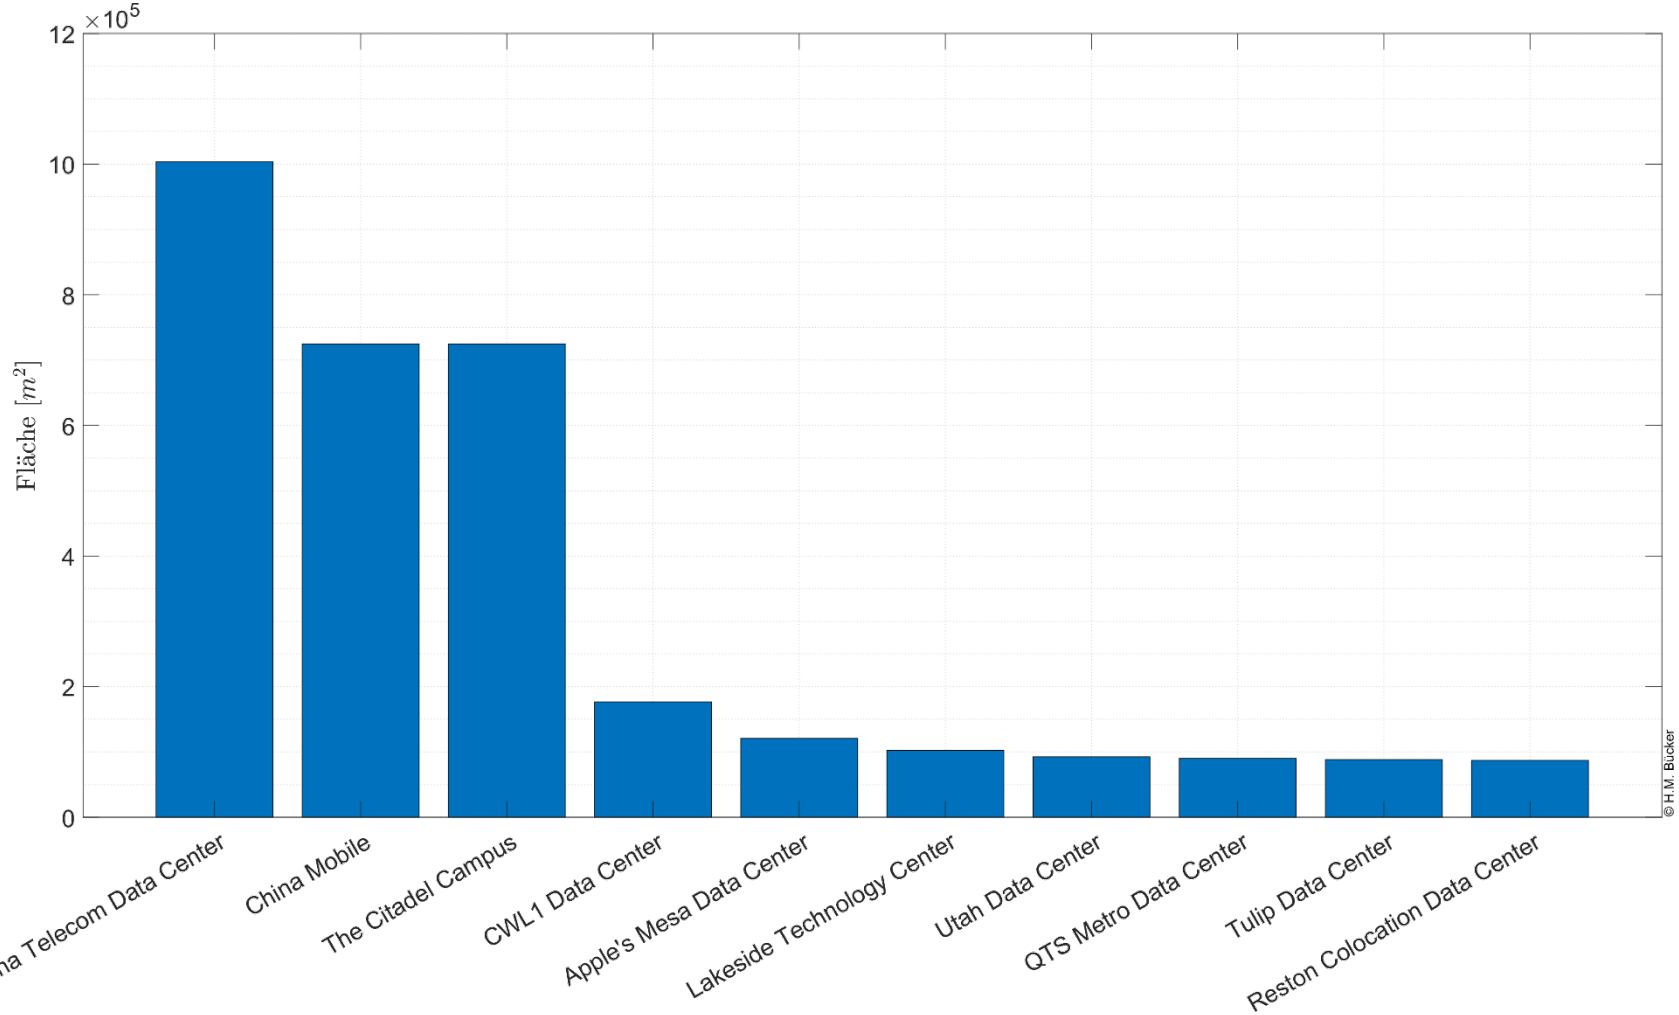
http://www.datacenterknowledge.com/special-report-the-worlds-largest-data-centers/

Top Ten List (as of 2024)

Data Centers

https://www.rankred.com/largest-data-centers-in-the-world/

Fläche $[m^2]$


×10^5
12
10
8
6
4
2
0
Fläche [m^2]
China Telecom Data Center
China Mobile
The Citadel Campus
CWL1 Data Center
Apple's Mesa Data Center
Lakeside Technology Center
Utah Data Center
QTS Metro Data Center
Tulip Data Center
Reston Colocation Data Center
© H.M. Bücker

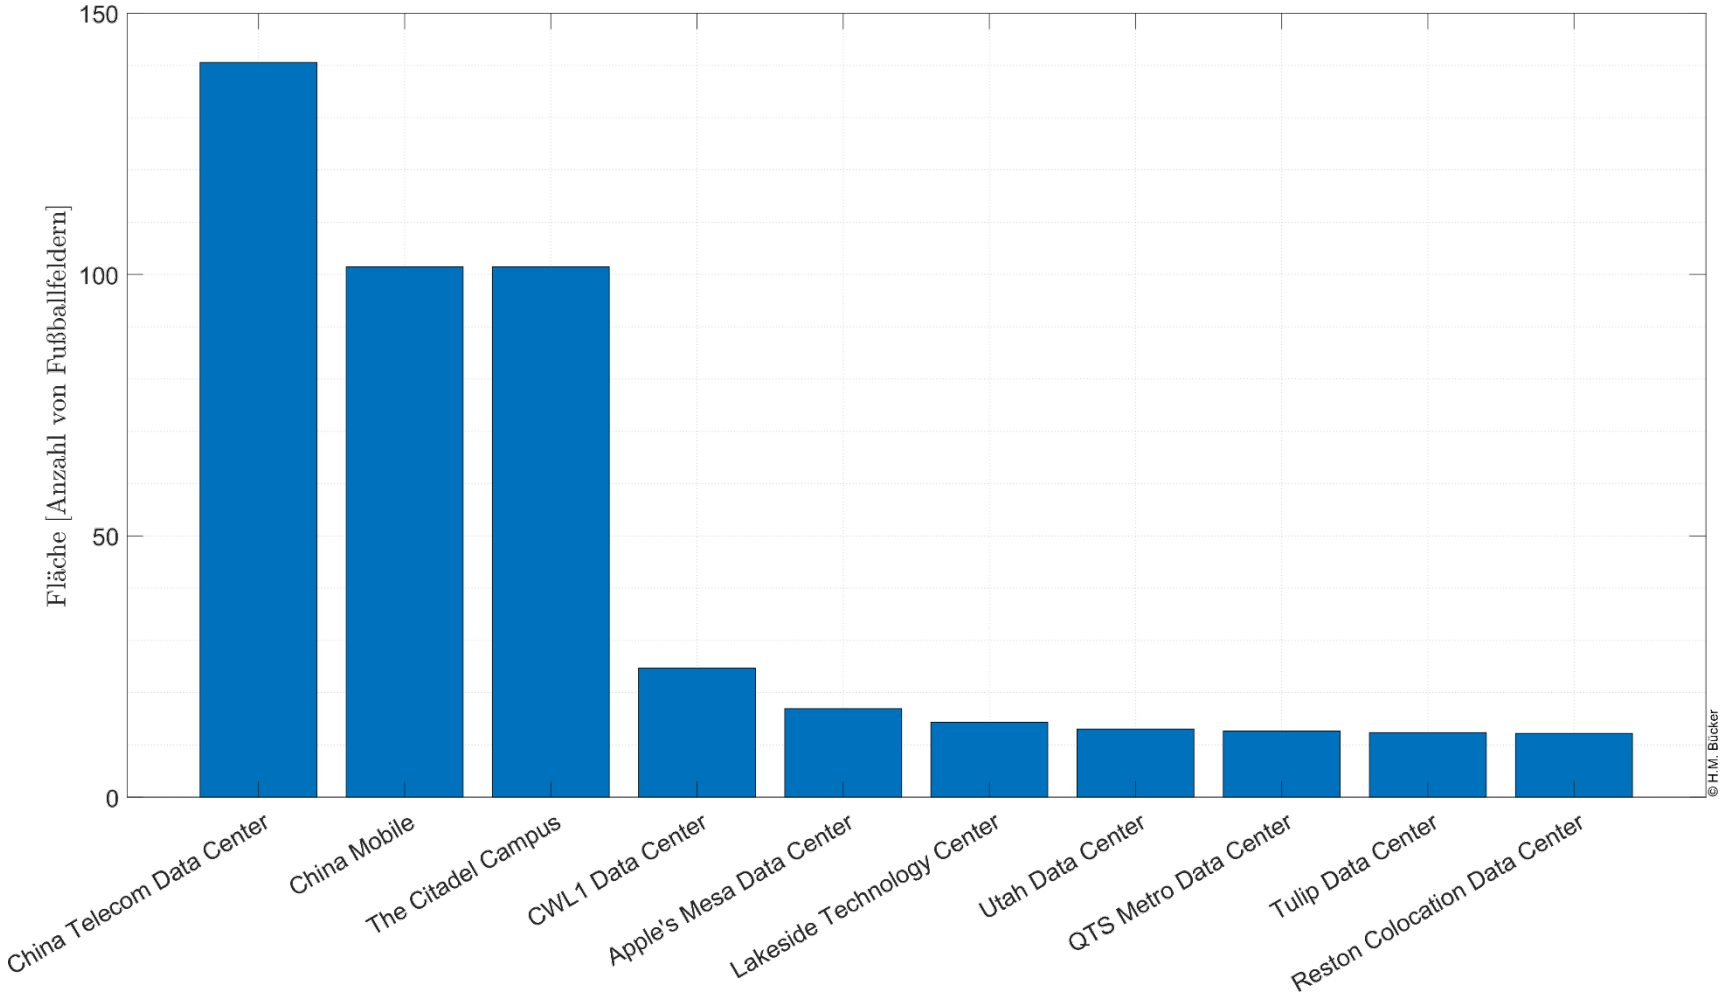
Ernst-Abbe-Stadium, Jena



Roman Möbius / elf5 Jena GmbH (https://commons.wikimedia.org/wiki/File:Ad_hoc_arena_im_Ernst_Abbe_Sportfeld_Foto_Roman_Moebius-%C2%A9-elf5-Jena-GmbH.jpg), https://creativecommons.org/licenses/by-sa/3.0/deed.en

$105\,m \times 68\,m$

Fläche [105 m × 68 m Fußballfelder]



Supercomputer oder Cluster

Kriterium	Supercomputer	Cluster
Hauptfokus	Performance	Productivity
Programmier-aufwand	sehr hoch	sehr niedrig
Hardware-Kosten	sehr hoch	preiswert
Hardware-Qualität	sehr hoch, stabile Komponenten	niedrig, ggf. unzuverlässig
Nutzung früher	Scientific Computing	Business
Nutzung heute	Computational & Data Science, …	